



طراحی مدل گروهی تخمین تراوایی مخزن هیدروکربوری با استفاده از نگاره‌های پتروفیزیکی بر اساس تفکیک لیتولوژیکی

عباس سلحشور^۱؛ احمد گایینی^۲؛ علیرضا شاهین^۳؛ مصیب کمری^۴

۱. دانشجوی دکترای تخصصی؛ مهندسی صنایع، دانشکده مهندسی صنایع، دانشگاه ایوانکی

۲. استادیار؛ مهندسی صنایع، دانشکده مهندسی صنایع، دانشگاه ایوانکی

۳. دکترای تخصصی؛ زمین‌شناسی، دانشکده علوم، دانشگاه اصفهان

۴. کارشناسی ارشد؛ مهندس ارشد پتروفیزیک، شرکت ملی مناطق نفت خیز جنوب

دریافت مقاله: ۱۴۰۰/۰۵/۰۷ پذیرش مقاله: ۱۴۰۰/۱۰/۲۲

شناسه دیجیتال (DOI): 10.22107 / jpg.2022.297342.1148

چکیده	واژگان کلیدی
تراوایی یا نفوذپذیری، یکی از خصوصیات مهم مخازن نفت و گاز است که پیش‌بینی آن دشوار می‌باشد. در حال حاضر از مدل‌های تجربی و رگرسیونی برای پیش‌بینی تراوایی استفاده می‌شود، از سوی دیگر افزایش دقت در پیش‌بینی تراوایی جهت نقاطی که فاقد نمونه مغزه است از اهمیت ویژه‌ای در تحلیل رفتار مخزن برخوردار است. در چند وقت اخیر، به دلیل قابلیت پیش‌بینی بهتر، از الگوریتم‌های یادگیری ماشین برای پیش‌بینی تراوایی استفاده شده است. در این مطالعه، مدل یادگیری ماشین گروهی جدیدی برای پیش‌بینی تراوایی در مخازن نفت و گاز معرفی شده است. در این روش، داده‌های ورودی با استفاده از اطلاعات لیتولوژی لاگ‌ها برچسب‌گذاری شده و به تعدادی از خوشه‌ها تفکیک می‌شوند و هر خوشه توسط الگوریتم یادگیری ماشین مدل‌سازی شد. برخلاف مطالعات قبلی که به صورت مستقل روی مدل‌ها کار می‌کردند در اینجا ما ضمن طراحی یک مدل گروهی با استفاده از الگوریتم‌های رگرسیون درخت تصمیم افزوده (ETR)، رگرسیون درخت تصمیم (DTR) و رگرسیون گرادیان تقویت شده (GBR) و داده‌های پتروفیزیکی، توانستیم صحت و دقت پیش‌بینی همچنین خطای میانگین مربعات را به طرز چشم‌گیری بهبود بخشیم و تراوایی را با دقت ۹۹.۸۲ درصد پیش‌بینی کنیم. نتایج نشان داد که مدل‌های گروهی در بهبود دقت پیش‌بینی تراوایی در مقایسه با مدل‌های انفرادی تأثیر فراوانی دارند و همچنین تفکیک نمونه‌ها بر اساس اطلاعات لیتوژی، دلیلی بر بهینه نمودن تخمین تراوایی نسبت به تحقیقات گذشته بود.	تراوایی، مدل گروهی، لیتولوژی، یادگیری ماشین، نگاره‌های پتروفیزیکی، تراوایی، مدل گروهی

۱. پیش‌گفتار

تراوایی توانایی سنگ‌های متخلخل در انتقال مایع است. کاربرد این متغیر مهم در مطالعات مخازن زیرزمینی نفت و گاز جهت مدیریت مخزن و فرآیندهای توسعه‌ی میدان‌های نفت و گاز، اجتناب‌ناپذیر است (Ramzi, 1998)، (North, 1985). از لحاظ ماهیت و مشکلات عملیاتی، تخمین این متغیر نسبت به برخی متغیرهای دیگر سنگ و سیال، دشوارتر است (Oberto, 1984). شیوه‌هایی که در حال حاضر معمول است

تعیین تراوایی و تخلخل مغزه در آزمایشگاه، به دست آوردن یک رگرسیون خطی بین این دو متغیر و تعمیم آن به کل چاه است که چندان مناسب نیست. یکی از مدل‌های ارائه شده برای تخمین تراوایی، مدل کوزنی-کارمن است، مدلی کوزنی-کارمن از ادغام دو قانون دارسی، برای جریان سیال در محیط متخلخل و مدل پوزای، برای جریان در لوله‌ها، به دست آمده است (Abbaszadeh et al., 1996). محاسبه تراوایی با استفاده از مدل کوزنی-کارمن، به علت وجود پارامترهای پیچیدگی مسیر جریان، فاکتور شکل و نسبت سطح حفره به حجم دانه، مشکل بوده از این رو محققان با

استفاده از روابط تخلخل-تراوایی در چارچوب واحدهای جریانیهیدرولیکی به منظور تعیین سنگ‌های مخزنی ناهمگن جهت بررسی دقیق رفتار مخزن و سیالات موجود در آن بهره‌برداری کردند. اولین مرحله پیش‌بینی رفتار مخزن طی تولید، تعیین گروه‌های سنگی مخزن است. با استفاده از گروه‌های سنگی مخزن می‌توان بخش‌های مخزنی را از بخش‌های غیر مخزنی تفکیک کرد (ایزدی، ۱۳۹۱). تلاش‌های مختلفی جهت تخمین تراوایی صورت گرفته که می‌توان آن‌ها را به دو دسته‌ی روش‌های تجربی و آماری تقسیم کرد. روش‌های آماری، روش‌های نوینی مبتنی بر هوش مصنوعی، شبکه‌های عصبی، منطق فازی و غیره هستند که بسیار کارآمد ظاهر شده‌اند. در این مقایسه باید تعداد متغیرهای مخزن مدنظر، کیفیت و حجم و تنوع اطلاعات آزمایشی انتخاب‌شده، همگن یا ناهمگن بودن مخزن که همگی بر دقت روش تأثیرگذار هستند را در نظر گرفت. در این مقاله سعی شده با استفاده از حداکثر متغیرهای در دسترس مرتبط با تراوایی (شامل نمودارهای پتروفیزیکی، طیف پرتو گاما، تخلخل، نوترون، چگالی سازند، صوتی، عامل فتوالکتریک، داده‌های تخلخل و درصد اشباع آب مغزه) به-عنوان ورودی و همچنین برچسب‌گذاری این مقادیر بر اساس اطلاعات لیتولوژی این نمودارها و تفکیک نمونه‌های مشابه در دسته‌های جداگانه، ضمن استفاده از ترکیب گروهی از الگوریتم‌های ماشین یادگیرنده (Ayyadevara, 2018) (Lakhmi, 2016) (درخت تصمیم، گرادیان تقویت‌شده و درخت تصمیم افزوده) (Schwartz, 2014) (Mitchell, 1997)، رویکرد و مدل جدیدی را برای تخمین تراوایی ارائه و طراحی نماییم.

در سال‌های گذشته مطالعات و پژوهش‌هایی در خصوص تخمین تراوایی مخزن با استفاده از روش‌های یادگیری ماشین انجام شده است. از جمله این پژوهش‌ها سلحشور و همکارانش در مقاله‌ای با عنوان بهینه‌سازی الگوریتم‌های یادگیری ماشین جهت تخمین تراوایی مخازن زیرزمینی نفت و گاز ارائه کردند، آن‌ها روش ماشین بردار پشتیبان با توابع هسته مختلف را جهت تخمین تراوایی استفاده کرده که در

نهایت توانستند با استفاده از روش رگرسیون بردار پشتیبان (SVR)^۱ و تابع هسته پایه شعاعی بهترین تخمین تراوایی را در یکی از مخازن نفتی با ضریب همبستگی ۹۶.۱ داشته باشند (سلحشور، ۱۳۹۳). در سال ۲۰۱۶، عبدالعزیز و همکاران تحقیقی با عنوان پیش‌بینی تراوایی بهبودیافته به وسیله داده‌های لرزه‌نگاری و داده‌های لاگ با استفاده از تکنیک‌های هوش مصنوعی انجام دادند. در این تحقیق، یک مطالعه مقایسه‌ای در پیش‌بینی تراوایی مخزن در اثر ترکیب مجموعه داده‌های لاگ چاه و لرزه‌نگاری انجام شد. این مطالعه با به کارگیری سه تکنیک پیشرفته هوش مصنوعی شامل شبکه‌های فازی (FN)^۲، ماشین بردار پشتیبان (SVM)^۳ و سیستم فازی نوع دوم (T2FLS)^۴، روی مجموعه داده‌های لرزه‌نگاری و لاگ به صورت ترکیبی، انجام شده است. مدل‌ها برای عملکرد مطلوب بهینه‌سازی شدند و مجموعه داده‌ها به ترتیب به زیرمجموعه‌های آموزش و آزمایش به دنبال الگوی یادگیری ماشین استاندارد قرار گرفتند. نتایج حاصل از این مطالعه نشان داد که ترکیب داده‌های لرزه‌نگاری و لاگ در مقایسه با استفاده سنتی از داده‌های لاگ و لرزه-نگاری به صورت مجزا عملکرد بهتری داشتند. آن‌ها مدل‌های ترکیبی از سیستم فازی نوع دوم، ماشین بردار پشتیبان و شبکه‌های فازی را تحت عنوان الگوریتم انتخاب ویژگی غیرخطی ارائه دادند، مقایسه نتایج مدل‌های ترکیبی از این سه الگوریتم نشان داد که روش ترکیبی FN-SVM با ضریب تعیین ۸۲ درصد و خطای میانگین مربعات ۰.۴۶ بهترین تخمین را به دست آورند (Fatai, 2016). طیبی در مقاله‌ای با عنوان مطالعه موردی تعیین تراوایی مخازن کربناته با استفاده از لاگ تشدید مغناطیسی هسته (NMR)^۵ در یکی از میداین جنوب غربی ایران از روش‌های نسبت تحویل رسوب (SDR)^۶ و Timur برای محاسبه تراوایی استفاده کردند دقت و صحت تخمین آن‌ها ۴۴.۱ درصد بود (طیبی، ۱۳۹۶). حکیمی نژاد و همکاران در سال ۲۰۱۷، پژوهشی بر روی داده‌های چهار چاه کنگان و دالان واقع در میدان پارس جنوبی ایران انجام دادند. آن‌ها با انتخاب ۸ ویژگی از هر چاه،

¹ Support Vector Regression

² Fuzzy Networks

³ Support Vector Machine

⁴ Type 2 Fuzzy Logic System

⁵ Nuclear Magnetic Resonance

⁶ Sediment Delivery Ratio

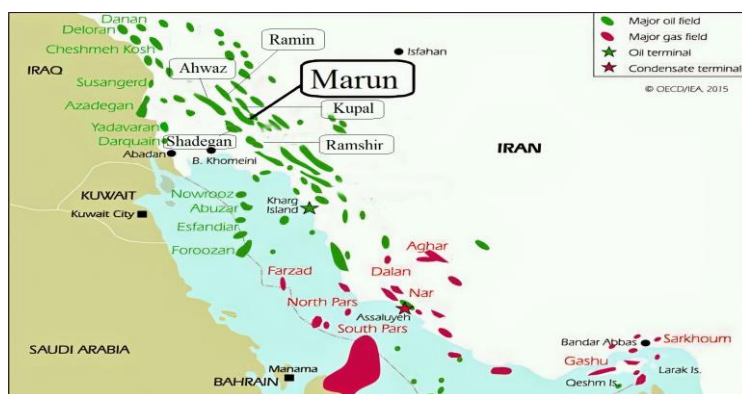
عصبی فازی ($ANFIS^7$) بهره بردند که موفق شدند با ضریب همبستگی ۹۵.۳۴ درصد تراوایی را تخمین بزنند. (Adeniran, 2019)، سباستین و همکاران در مقاله تخمین تراوایی مطلق با استفاده از شبکه‌های عصبی بر اساس لاگ-های چاه و داده‌های آزمایشگاهی در سال ۲۰۱۹، توانستند با ضریب همبستگی ۷۳ درصدی بین تراوایی حاصل از داده-های آزمایشگاه و تراوایی حاصل از شبکه عصبی کار خود را ارائه دهند (Waszkiewicz, 2019).

۱.۱ موقعیت جغرافیایی و ویژگی‌های ساختمانی

میدان نفتی مارون

میدان نفتی مارون در سال ۱۹۶۳ به روش لرزه‌نگاری دوبعدی کشف شد. این میدان بزرگ نفتی در فروافتادگی دزفول حدود ۴۵ کیلومتری جنوب شرقی اهواز قرار دارد (میرزاقلی‌پور و حقی، ۱۳۶۹). روند محوری این میدان شمال غربی-جنوب شرقی است. میدان مارون در مخزن آسماری دارای طول ۶۷ کیلومتر و عرض متوسط ۵/۵ کیلومتر می‌باشد که بیشترین و کمترین عرض آن به ترتیب ۷ و ۳/۵ کیلومتر می‌باشد. موقعیت جغرافیایی این میدان نسبت به میدان‌های مجاور همان‌طور که در شکل (۱) نشان داده شده است، از شمال توسط میدان رامین، از شرق توسط میدان کوپال، از غرب و شمال غرب توسط میدان‌های شادگان و اهواز و از جنوب توسط میدان رامشیر محدود می‌شود (سراج، ۱۳۸۴).

با استفاده از روش انتخاب ویژگی مبتنی بر همبستگی، چهار ویژگی مؤثر در هر چاه را انتخاب کردند. سپس از روش‌های رگرسیون، شبکه عصبی چندلایه، مدل درخت خطی، سیستم فازی نوع یک و سیستم فازی نوع دو برای پیش‌بینی تراوایی استفاده کردند. نتایج نشان داد که با توجه به وجود عدم قطعیت در پارامترهای پتروفیزیکی و تراوایی، سیستم فازی نوع دو عدم قطعیت‌ها را بهتر پوشش می‌دهد. این روش در حالت پایه، تراوایی را با دقت ۰.۹۴۸۱ و ریشه دوم میانگین مربعات خطا ۰.۳۰۶۰ پیش‌بینی کرد که با استفاده از روش ترکیبی الگوریتم ژنتیک و الگوریتم جستجوی گرانشی، توابع عضویت فازی بهبود یافت و این بهبودها منجر به افزایش دقت پیش‌بینی تراوایی با ضریب تعیین ۰.۹۷۶۸ و کاهش ریشه دوم میانگین مربعات خطا به مقدار ۰.۱۶۰۲ شد (حکیمی نژاد، ۱۳۹۷). در سال ۲۰۱۸، احمدی و همکاران، مقایسه روش‌های یادگیری ماشین برای تخمین تراوایی و تخلخل مخازن نفتی با استفاده از نگاره‌های پتروفیزیکی، روش ترکیبی $HGAPSO-LSSVM$ را ارائه دادند (Ahmadi & Zhangxing, 2018). در سال ۲۰۱۹، ادنیران یک مدل گروهی رقابتی برای پیش‌بینی تراوایی در مخازن ناهمگن نفت و گاز ارائه کرد نتایج نشان داد که مدل-های گروهی رقابتی، دقت پیش‌بینی بهتری در تخمین تراوایی دارد، آن‌ها از یک مدل گروهی برای تخمین تراوایی شامل ماشین‌های شبکه عصبی مصنوعی (ANN) و ماشین بردار پشتیبان (SVM) و سیستم‌های تطبیقی استنتاج



شکل ۱. موقعیت جغرافیایی میدان نفتی مارون (Amiri Bakhtiyar et al., 2018)

⁷ Adaptive network-based fuzzy inference system

۲. روش کار

در این مطالعه روش تحلیل مطابق شکل (۱) ارائه شده است. به این ترتیب که ابتدا روش‌های یادگیری ماشین غیرخطی که تاکنون در تخمین تراوایی کمتر استفاده شده و همچنین جزو الگوریتم‌های قوی در یادگیری می‌باشند انتخاب شده‌اند، سپس اطلاعات مربوط به لاگ‌های پتروفیزیکی در اختیار قرار داده می‌شود، اطلاعات مربوطه پس از استانداردسازی در بازه ۰ تا ۱، بر اساس حجم مقادیر لیتولوژی در هر رکورد، یکی از برچسب‌های ماسه‌سنگ^۸، کلسیت^۹، دولومیت^{۱۰}، شیل^{۱۱} و انیدریت^{۱۲} را به خود اختصاص می‌دهد و داده‌ها بر این اساس تفکیک می‌شوند. آنگاه به ازای هر خوشه، مدل-های یادگیری ماشین کی-نزدیکترین همسایه (^{۱۳}KNR)، رگرسیون جنگل تصادفی (^{۱۴}RFR)، رگرسیون درخت

تصمیم (^{۱۵}DTR)، رگرسیون گاوسی تقویت‌شده (^{۱۶}GBR)، رگرسیون سازگار تقویت‌شده (^{۱۷}ABR) و رگرسیون درخت افزوده (^{۱۸}ETR) با پارامترهای مختلف در هر مدل و در تکرارهای مشابه بررسی خواهد شد. سپس سه مدل از الگوریتم‌هایی که بهترین عملکرد را دارند برای تشکیل یک ماشین گروهی انتخاب می‌شوند که معیار ارزیابی عملکرد کارایی مدل‌ها، ضریب همبستگی بین مقادیر تخمین زده شده و مقادیر واقعی تراوایی و همچنین خطای میانگین مربعات می‌باشد. از اینجا به بعد مدل ترکیبی گروهی ساخته شده به ازای مقادیر مختلف پارامترهای ورودی و همچنین وزن دهی متفاوت به مدل‌های درون ماشین که سه مدل می‌باشد ارزیابی خواهد شد و بهترین عملکرد ماشین به عنوان مدل نهایی طراحی شده برگزیده خواهد شد.

⁸ Sand Stone

⁹ Calcite

¹⁰ Dolomite

¹¹ Shale

¹² Anhydrite

¹³ K Nearest Neighbor Regressor

¹⁴ Random Forest Regressor

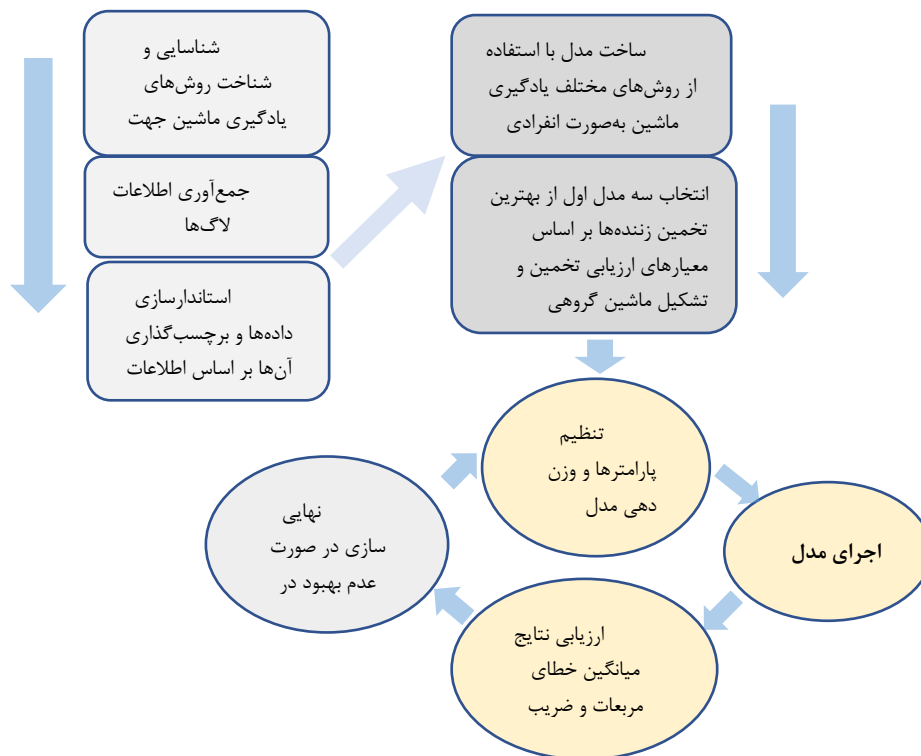
¹⁵ Decision Tree Regressor

¹⁶ Gaussian Boost Regressor

¹⁷ Adaptive Boosting Regressor

¹⁸ Extra Tree Regressor

طراحی مدل گروهی تخمین تراوایی مخزن هیدروکربوری با استفاده از نگاره‌های پتروفیزیکی بر اساس تفکیک لیتولوژیکی



شکل ۱. گام‌های تحلیل مسئله

۱.۲ شناخت و آماده‌سازی داده‌ها

در این مطالعه ابتدا تعداد ۷۷۸۵ رکورد مربوط به ویژگی‌های پرتو گاما^{۱۹}، چگالی^{۲۰}، مقاومت الکتریکی^{۲۱}، نوترون^{۲۲}، اشباع آب^{۲۳}، فتوالکتریک^{۲۴}، تخلخل مؤثر^{۲۵} و اطلاعات لیتولوژی شامل حجم کلسیت، حجم دولومیت، حجم ماسه‌سنگ، حجم شیل، حجم انیدریت، از لاگ‌های چاه‌های به همراه تراوایی که از داده‌های مغزه پس از هم عمق سازی با داده‌های لاگ از همان چاه به دست آمده، مشتمل بر تعداد ۱۴ چاه از مخزن نفتی مارون ایران انتخاب شد.

مجموعه‌ای آموزشی به صورت تصادفی از روی داده‌های لاگ-های مربوط به ۱۴ چاه انتخاب شده و مجموعه آزمایشی نیز به صورت تصادفی از بین داده‌های کل ۱۴ چاه انتخاب شده است. در هر نمونه آزمایشی و آموزشی دو مجموعه داده وجود دارد، که در نهایت به صورت زیر دسته‌بندی خواهند شد:

$$\{(x_1, y_2), \dots, (x_1, y_2) \in R^N, y \in \} \quad (1)$$

که x_i به صورت زیر می‌باشند:

$$Xi = (DT, CGR, PEF, RHOB, NPHI, RT, SW, Yi = Perm \text{ و } POR)$$

بدین ترتیب که تراوایی به عنوان پارامتر خروجی و به مقادیر

¹⁹ Gamma Ray

²⁰ Density

²¹ Resistivity Environmentally

²² Neutron

²³ Water Saturation

²⁴ Photoelectric Factor

²⁵ Effective Porosity

لاگ پرتو گاما، تخلخل، پرتو الکتریکی، چگالی، نوترون، سونیک، مقدار اشباع، فتوالکتریک به عنوان بردار ورودی می باشد.

۲.۲ خوشه بندی

تحلیل خوشه‌ای^{۲۶} یا به طور خلاصه خوشه بندی، فرآیندی است که به کمک آن می توان مجموعه‌ای از اشیاء را به گروه‌های مجزا افراز کرد. هر افراز یک خوشه نامیده می شود. اعضاء هر خوشه با توجه به ویژگی‌هایی که دارند به یکدیگر بسیار شبیه هستند و در عوض میزان شباهت بین خوشه‌ها کمترین مقدار است. در چنین حالتی هدف از خوشه بندی، نسبت دادن برچسب‌هایی به اشیاء است که نشان دهنده عضویت هر شیء به خوشه است. در تحلیل خوشه‌ای بر خلاف دسته بندی^{۲۷}، به دلیل عدم وجود برچسب‌های اولیه به عنوان یک روش غیر نظارتی می باشد. در این روش، بر اساس ویژگی‌های مشترک و روش‌های اندازه گیری فاصله یا شباهت بین اشیاء، باید برچسب‌هایی به طور خودکار نسبت داده شوند. درحالی که در دسته بندی برچسب‌های اولیه موجود است و باید با استفاده از الگوهای پیش بینی قادر به برچسب گذاری برای مشاهدات جدید باشیم (Aggarwal & Reddy, 2014).

اگرچه بیشتر الگوریتم‌ها یا روش‌های خوشه بندی مبنای

یکسانی دارند ولی تفاوت‌هایی در شیوه اندازه گیری شباهت یا فاصله و همچنین انتخاب برچسب برای اشیاء هر خوشه در این روش‌ها وجود دارد. به طور کلی چهار گروه اصلی برای الگوریتم‌های خوشه بندی وجود دارد. الگوریتم‌های خوشه بندی تفکیکی، الگوریتم‌های خوشه بندی سلسله مراتبی، الگوریتم‌های خوشه بندی بر مبنای چگالی و الگوریتم‌های خوشه بندی بر مبنای مدل (Lakmi, 2016). در این مطالعه روش خوشه بندی کی-میانگین (خوشه بندی تفکیکی)، مورد بررسی قرار گرفته است (Wang, 2003).

۳.۲ برچسب گذاری داده‌ها بر حسب اطلاعات

لیتولوژی

در این قسمت داده‌های ورودی را به ازای هر رکورد مطابق جدول (۱) برچسب گذاری می کنیم. بدین گونه که اطلاعات لیتولوژی شامل ستون‌های حجم کربنات، حجم دولومیت، حجم ماسه سنگ، حجم شل در هر نمونه را بررسی کرده و چنانچه مقدار هر کدام از آن‌ها از سایر ستون‌های دیگر بیشتر باشد برچسب آن رکورد را مطابق ستون گونه سنگ در جدول (۱) به خود اختصاص می دهد. درنهایت داده‌ها در چهار خوشه تقسیم بندی می شوند که هر خوشه به صورت مجزا برای مدل تخمین زننده به عنوان ورودی انتخاب خواهد شد.

جدول ۱ شمای کلی از برچسب‌های اطلاعات ورودی

عمق لاگ	عمق مغزه	حجم کلسیت	حجم دولومیت	حجم ماسه	حجم شیل	حجم انیدریت	گونه سنگ
۲۹۵۸.۵۴۱	۲۹۵۸.۲۵	۰.۸۵۳	۰.۱۴۷	۰	۰	۰	Calcite
۲۹۶۰.۶۷۵	۲۹۶۰.۷۱	۰.۴۷۴۶	۰.۵۲۵۴	۰	۰	۰	Dolomite
۳۰۲۳.۹۲۱	۳۰۲۳.۵۳	۰.۲۳۳۶	۰	۰.۷۶۶۴	۰	۰	Sand
۳۱۱۳.۰۷۵	۳۱۱۳.۱۱	۰	۰.۱۶۳	۰	۰.۹۸۳۷	۰	Shale

در آن، همه‌ی مقادیر بین صفر و یک می باشند:

$$Z_i = \frac{x_i - x_{min}}{x_{max} - x_{min}} \quad (2)$$

که در آن Z_i مقدار استاندارد شده، x_i مقدار هریک از داده‌ها، x_{min} حداقل کل داده‌ها x_{max} حداکثر مقدار داده‌ها می باشد.

۴.۲ انتخاب روش استاندارد سازی داده‌ها

روش‌های مختلفی برای استاندارد سازی وجود دارد که در تمام این روش‌ها داده‌ها طوری تبدیل می شوند که شرایط مورد نظر تأمین گردد. یکی از مهم ترین روش‌های استاندارد سازی، تبدیل داده‌ها به مجموعه جدیدی است که

²⁶ Cluster Analysis

²⁷ Classification

طراحی مدل گروهی تخمین تراوایی مخزن هیدروکربوری با استفاده از نگاره‌های پتروفیزیکی بر اساس تفکیک لیتولوژیکی

۵.۲ روش ارزیابی استفاده شده

نتایج به دست آمده از الگوریتم‌های مورد استفاده از لحاظ دقت، صحت، مقدار و کیفیت مورد بررسی قرار گیرند تا بتوان بهترین حالت برای مدل سازی را انتخاب نمود لذا روش به دست آوردن این کمیت‌ها در زیر توضیح داده شده است.

خطای میانگین مربعات^{۲۸}:

(۳)

$$MSE = (\sum Actual - Forecast)^2 / n = \sum (Error)^2 / n$$

رابطه‌ی ۳، خطای میانگین مربعات است که در آن n ، تعداد نمونه‌های تخمینی، $Actual$ ، مقدار واقعی هر برچسب و $Forecast$ ، مقدار تخمینی برای هر یک است. هر چه مقدار کمیت MSE کمتر باشد، ضریب خطا نیز کمتر خواهد بود. ضریب همبستگی، شدت رابطه و همچنین نوع رابطه (مستقیم یا معکوس) را نشان می‌دهد. این ضریب بین (۱) تا (۱-) است و در حالت عدم وجود رابطه بین دو متغیر، برابر صفر می‌باشد. همبستگی بین دو متغیر تصادفی X و Y به صورت رابطه‌ی ۴- تعریف می‌شود:

(۴)

$$Corr(X, Y) = \frac{Cov(X, Y)}{\sigma_X \sigma_Y} = \frac{E[(X - \mu_X)(Y - \mu_Y)]}{\sigma_X \sigma_Y}$$

که در آن E عملگر امید ریاضی، cov به معنای کوواریانس، $corr$ نماد معمول برای همبستگی پیرسون و σ نماد انحراف معیار است.

۶.۲ آموزش و ساخت مدل

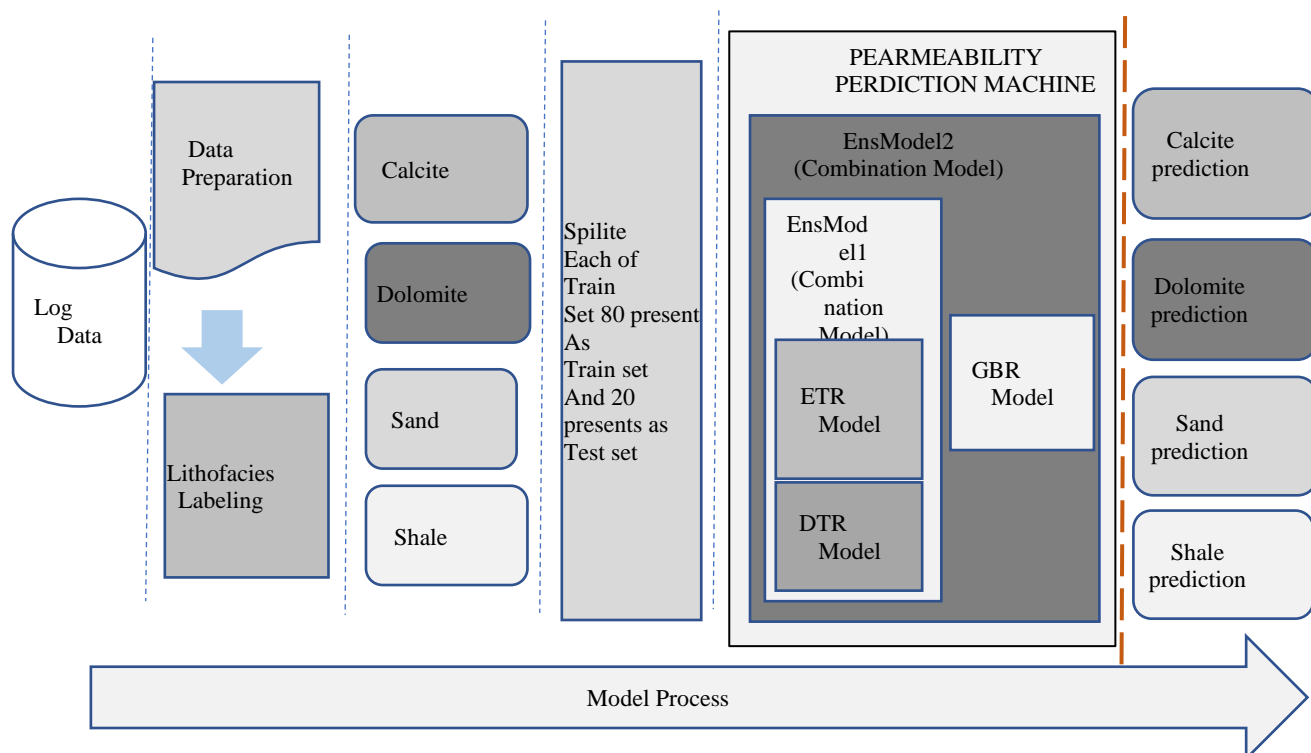
در این مرحله ابتدا داده‌ها را بر اساس اطلاعات برچسب گذاری شده در بخش ۲-۳ به چهار خوشه A ، B ،

جدول ۲ نتایج اجرای روش‌های یادگیری شش گانه بر روی ۴ خوشه ورودی

خوشه D	خوشه C	خوشه B	خوشه A	معیار ارزیابی	الگوریتم یادگیری ماشین
تعداد: ۲۸۵۰	تعداد: ۹۵۶	تعداد: ۳۵۶۷	تعداد: ۴۱۲		
۸۸.۰۵	۷۴.۵	۸۱.۷	۸۳.۶	R^2	ETR
۳۱(e-۰۶)	۴۲(e-۰۶)	۳۶(e-۰۶)	۳۴(e-۰۶)	MSE	
۷۱.۸۸	۵۳.۳۷	۶۰.۱۳	۷۹.۵	R^2	

²⁸ MEAN SQUARE ERROR

$68(e-06)$	$86(e-05)$	$54(e-05)$	$63(e-06)$	<i>MSE</i>	RFR
۷۳.۶	۶۴.۹	۵۵.۷	۷۵.۴	R^2	KNR
$69(e-06)$	$51(e-06)$	$81(e-05)$	$69(e-06)$	<i>MSE</i>	
۴۷.۰۲	۲۳.۸۹	۴۹.۴۴	۳۸.۶۶	R^2	ABR
$79(e-05)$	$94(e-04)$	$81(e-05)$	$89(e-05)$	<i>MSE</i>	
۷۸.۱۱	۷۸.۲۲	۶۸.۳۳	۶۴.۰	R^2	GBR
$39(e-06)$	$38(e-06)$	$55(e-05)$	$51(e-06)$	<i>MSE</i>	
۸۲.۹	۷۱.۳	۷۷.۲۲	۹۶.۲	R^2	DTR
$38(e-06)$	$68(e-06)$	$41(e-06)$	$8.1(e-06)$	<i>MSE</i>	



شکل ۲. شمای اجرا شده در آموزش مدل و تخمین تراوایی

آموزش و ۲۰ درصد داده‌ها به‌عنوان مجموعه آزمایشی انتخاب شدند و پس از اجرای مدل گروهی، نتایج در جدول (۳) نمایش داده‌شده است.

در مرحله بعد، جهت مقایسه نتایج در حالت پیش از تفکیک گونه‌های سنگی، داده‌های اولیه شامل تعداد ۷۷۸۵ نمونه که بر اساس مقدار خصوصیت عمق نمونه مرتب‌سازی شده و بدون اینکه تفکیکی انجام شود توسط مدل گروهی آموزش داده شد به‌نحوی که ۸۰ درصد داده‌ها به‌عنوان مجموعه

طراحی مدل گروهی تخمین تراوایی مخزن هیدروکربوری با استفاده از نگاره‌های پتروفیزیکی بر اساس تفکیک لیتولوژیکی

جدول ۳. نتایج اجرای مدل گروهی تخمین تراوایی قبل از خوشه‌بندی			
تعداد داده‌های مجموعه آزمایش	R^2	MSE	MAE
۱۵۵۶	۹۵.۷	$۷.۶۱۰۱۵ (e-۵)$	۰.۰۰۱۶۶۸

مدل به تفکیک برچسب‌گذاری داده‌ها و میزان کمیت هر خوشه، همچنین ضریب تعیین و خطای میانگین مربعات و خطای مطلق میانگین آورده شده است.


۳. نتایج

در این مقاله با استفاده از روش‌های یادگیری شش‌گانه یک مدل ترکیبی گروهی شامل سه روش ETR ، DTR و GBR مطابق شکل (۲)، طراحی شد که در جدول (۴) نتایج اجرای

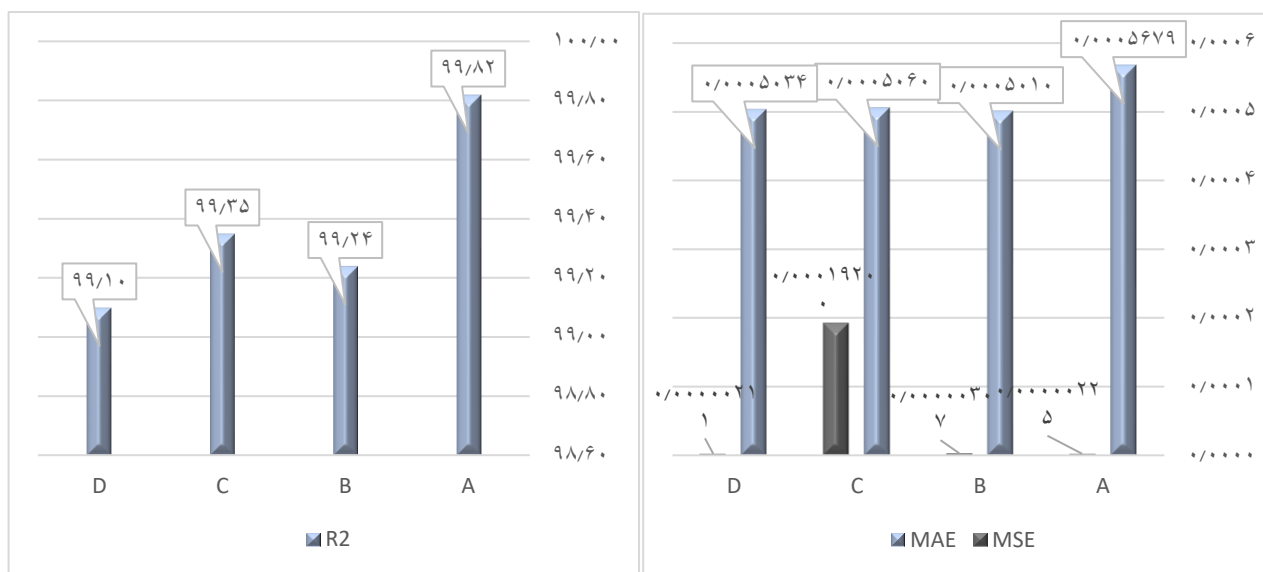
جدول ۴ نتایج اجرای مدل گروهی تخمین تراوایی				
نام خوشه	تعداد نمونه در خوشه	R^2	MSE	MAE
A	۴۱۲	۹۹.۸۲	$۲.۲۵۰۸۴ (e-۶)$	۰.۰۰۰۵۶۷۹۳۱
B	۳۵۶۷	۹۹.۲۴	$۳.۰۶۷۵ (e-۶)$	۰.۰۰۰۵۰۰۹۷۲
C	۹۵۶	۹۹.۳۵	۰.۰۰۰۱۹۲۰	۰.۰۰۰۵۰۶
D	۲۸۵۰	۹۹.۱	$۲.۱۰۹۲ (e-۶)$	۰.۰۰۰۵۰۳۴۱

که نشان‌دهنده تأثیر تفکیک گونه‌های سنگی در دقت تخمین می‌باشد.

در شکل (۳) میزان تراوایی تخمین زده‌شده بر اساس تراوایی واقعی، پیش از خوشه‌بندی و تفکیک گونه‌های سنگی بر اساس اطلاعات لیتولوژی نمایش داده‌شده است



شکل ۳ نمودار تخمین تراوایی با استفاده از مدل گروهی پیش از تفکیک گونه‌های سنگی




شکل ۴. نمودار مقایسه خطا برای هر خوشه

شکل ۵. نمودار مقایسه R² برای هر خوشه

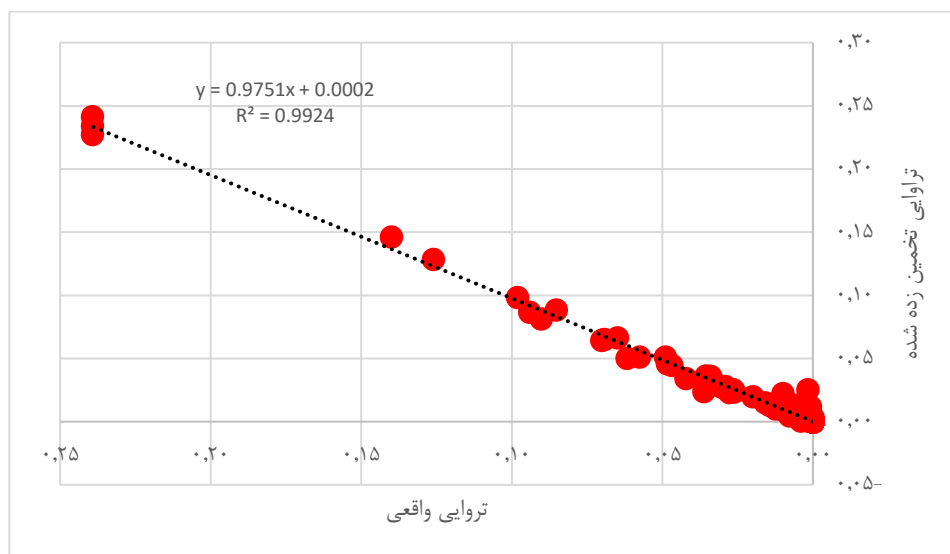
همبستگی جهت تخمین تراوایی بر اساس هر خوشه نمایش داده شده است.

در شکل (۴) خطای میانگین مربعات و خطای مطلق مربعات بر اساس خوشه‌ها نمایش داده شده است. در شکل (۵) ضریب



شکل ۶. نمودار تخمین تراوایی برای خوشه A (شل)


طراحی مدل گروهی تخمین تراوایی مخزن هیدروکربوری با استفاده از نگاره‌های پتروفیزیکی بر اساس تفکیک لیتولوژیکی




شکل ۷. نمودار تخمین تراوایی برای خوشه B (کلسیت)

تراوایی تخمین زده شده در مقابل میزان واقعی تراوایی برای خوشه B نمایش داده شده است.

در شکل (۵) تراوایی تخمین زده شده در مقابل میزان واقعی تراوایی برای خوشه A نمایش داده شده است. در شکل (۶)



شکل ۸. نمودار تخمین تراوایی برای خوشه C (ماسه سنگ)



شکل ۹. نمودار تخمین تراوایی برای خوشه D (دولومیت)

بر نتایج دسته‌های دیگر یک عامل جهت اختلاف بین دقت تخمین، تعداد نمونه‌های هر خوشه می‌باشد، البته کیفیت مقادیر نمونه‌ها نیز در تخمین بی‌تأثیر نبوده است. همچنین جهت برازش مدل با استفاده از شاخص ریشه میانگین مربعات باقیمانده ($RMSE^2$)، چنانچه این شاخص کمتر از ۰.۰۵ باشد نشان‌دهنده نیکویی برازش مدل بر داده‌ها است و مطابق جدول (۵)، این موضوع به‌وضوح مشخص است. از سوی دیگر همان‌طور که در نمودارهای ۶ تا ۹ نمایش داده‌شده، داده‌ها در هر خوشه متنوع بوده و بیشتر تمرکز داده از لحاظ کمیت بین ۰ تا ۰.۰۵ می‌باشد. نتایج دقت تخمین این پژوهش در مقایسه با مطالعات بخش ۱ بیانگر توانایی بالای مدل طراحی‌شده نسبت به سایر روش‌ها است.

در شکل (۸) تراوایی تخمین زده‌شده در مقابل میزان واقعی تراوایی برای خوشه C نمایش داده‌شده است. در شکل (۹) تراوایی تخمین زده‌شده در مقابل میزان واقعی تراوایی برای خوشه D نمایش داده‌شده است.

۴. بحث و بررسی

بررسی نتایج جدول شماره (۴) نشان می‌دهد که مدل ترکیبی گروهی نتایج بسیار خوبی برای همه خوشه‌ها که شامل تخمین تراوایی با ضریب تعیین میانگین ۹۹.۳۷۷ و میانگین خطای میانگین مربعات ۰.۰۰۰۰۴۹۸ بوده و بهترین تخمین را برای خوشه A با شاخص ضریب تعیین ۹۹.۸۲ و خطای میانگین مربعات $2.25084(e-06)$ حاصل شده است. همچنین با نگاهی

جدول ۵ برازش مدل بر خوشه‌ها

نام خوشه	تعداد نمونه‌های خوشه	ریشه میانگین مربعات باقیمانده
A	۴۱۲	۰.۰۰۱۵
B	۳۵۶۷	۰.۰۰۱۷
C	۹۵۶	۰.۰۱۳۸
D	۲۸۵۰	۰.۰۰۱۴

²⁹ Root Mean Square Residual

طراحی مدل گروهی تخمین تراوایی مخزن هیدروکربوری با استفاده از نگاره‌های پتروفیزیکی بر اساس تفکیک لیتولوژیکی

۵. نتیجه‌گیری

در این پژوهش برای پیش‌بینی تراوایی از روش‌های یادگیری ماشین به‌عنوان راهکاری جایگزین برای روش‌های تجربی و آزمایشگاهی استفاده شد و ضمن طراحی یک مدل گروهی جهت تخمین تراوایی، نتایج بسیار خوب زیر نیز به دست آمد:

تخمین تراوایی با دقت بسیار بالا و با ضریب همبستگی ۹۹.۷۶ درصد و ضریب خطا به میزان 2.25×10^{-4} (e-۰۶) استفاده از روش گروهی مدل‌های یادگیری ماشین که باعث تقویت نتایج تخمین خواهد شد.

تأثیر تفکیک سنگ‌ها بر اساس اطلاعات لیتولوژی و ارتباط مؤثر

۷. مراجع

- North, F.K (1985) Petroleum Geology, Allen & Unwin.
- Ramzi, H.R (1998) Well Logging, SANAM Publishing.
- Oberto, S. (1984) Fundamentals of Well-Log Interpretation – The Acquisition of Logging Data, Elsevier.
- Ayyadevara, V. (2018) Pro Machine Learning Algorithms, Apress.
- Abbaszadeh, M., Fuji, H. and Fujimoto, F., (1996) Permeability prediction by hydraulic flow units-theory and applications. SPE Formation Evaluation, Vol. 11, No. 4, pp 263- 271.
- Lakhmi, C. Jain (2016) Foundations and Methods in Combinatorial and Statistical Data Analysis and Clustering, Springer Press.
- Shalev-Schwartz, Sh. (2014) understanding-machine-learning-theory-algorithms, Cambridge University Press.
- Aggarwal, C. C. & Reddy, C. K. (eds.) (2014). Data Clustering: Algorithms and Applications. CRC Press.
- Wang, J. (2003). Data Mining: Opportunities and Challenges, USA Montclair, IRM Press.
- Mitchell, M. (1997) Machine-Learning-Tom-Mitchell, McGraw-Hill.
- Ahmadi, Mohammad. ali. & Zhangxing, Chen (2018), Comparison of machine learning methods for estimating permeability and porosity of oil reservoirs via Petro-physical logs, KeAi Elsevier, 6, 2:831-844.
- Adeniran A. (2019) A competitive ensemble model for permeability prediction in heterogeneous oil and gas reservoirs, Elsevier Paper, 4, 80:353-367.

- Waszkiewicz, S., rakowska-Madejska, P., Puskarczyk, E. (2019), Estimation of absolute permeability using artificial neural networks (Multilayer perceptron) based on well logs and laboratory data from Silurian and Ordovician deposits in SE Poland, Springer, 6, 67:1885–1894.
- Fatai, A., Abdulazeez, A., Abdullatif, A. (2016), Improved Permeability Prediction from Seismic and Log Data using Artificial Intelligence Techniques, SPE 164465, pp 1-3.
- Amiri Bakhtiyar, H., A. Telmadarreie, M. Shayesteh, M. H. Heidari Fard, H. Talebi, and Z. Shirband. (2018). Estimating Total Organic Carbon Content and Source Rock Evaluation, Applying $\Delta\log R$ and Neural Network Methods: Ahwaz and Marun Oilfields SW of Iran. Petroleum Science and Technology, Vol. 29, No. 16, pp 1691–1704. <https://doi.org/10.1080/10916461003620495>
- ایزدی م. (۱۳۹۱) "محاسبه تراوایی در چاه‌های فاقد مغزه با استفاده از مفهوم واحدهای جریان‌ی هیدرولیکی"، مجله اکتشاف و تولید نفت، ۱۱، ۹۸: صفحات ۶۸-۶۵.
- سلحشور ع، سهیلی ف.، کمری م. (۱۳۹۳) "بهینه‌سازی الگوریتم‌های یادگیری ماشین جهت تخمین تراوایی مخازن زیرزمینی نفت و گاز"، مجله اکتشاف و تولید نفت، ۱۲۰، ۳: صفحات ۶۲-۵۶.
- طیبی ه.، حبیب نیا ب. (۱۳۹۶) "مطالعه موردی تعیین تراوایی مخازن کربناته با استفاده از لاگ NMR در یکی از میادین جنوب غربی ایران"، مجله علمی پژوهشی زمین‌شناسی نفت ایران، ۷، ۱۳: صفحات ۶۲-۴۳.
- حکیمی نژاد ح.، میرزارضایی م.، نجار اعرابی ب. (۱۳۹۷) "پیش‌بینی تراوایی سنگ مخزن با استفاده از روش‌های عدم قطعیت سیستم فازی نوع دو"، مجله علمی پژوهشی ژئوفیزیک ایران، ۱۲۰، ۱: صفحات ۹۱-۸۲.
- میرزا قلی پور، علی؛ حق، عبدالحمید (۱۳۶۹). مطالعه زمین‌شناسی میدان نفتی مارون، گزارش شماره پ-۴۲۱۰، اداره کل زمین‌شناسی گسترشی، شرکت ملی مناطق نفت‌خیز جنوب، ص ۵۵.
- سراج، م. (۱۳۸۴). تحلیل ساختاری مقدماتی میادین نفتی مناطق نفت‌خیز جنوب (محدوده فروافتادگی دزفول شمالی)، گزارش شماره پ-۵۶۱۳، شرکت ملی مناطق نفت‌خیز جنوب.